

UNIVERSIDAD DEL VALLE DE GUATEMALA

Master In Business Intelligence And Analytics



Análisis de sentimiento y modelado de tópicos de Amazon Reviews

Curso: Text Analytics

Carlos Rivera Yong (251518)

Daniel Alejandro Cabrera (252136)

Alejandra Alvarado Jiménez (18263)

Guatemala, marzo 2026

I. INTRODUCCIÓN

El presente proyecto aborda el desafío de la gestión masiva de retroalimentación de clientes en el ecosistema de Amazon. El análisis busca transformar datos no estructurados (reseñas de texto) en conocimiento accionable para la toma de decisiones estratégicas. El enfoque principal es identificar automáticamente el sentimiento del usuario e interpretar los tópicos subyacentes que impulsan dicha percepción. Esto combinando tres enfoques metodológicos:

- Análisis basado en reglas léxicas: Uso de VADER como modelo base (baseline).
- Aprendizaje Supervisado: Comparativa entre Naive Bayes y Regresión Logística para clasificación de sentimiento.
- Aprendizaje No Supervisado: Descubrimiento de temas mediante Modelado de Tópicos (LDA).


II. FUENTE DE DATOS

Se utilizó un dataset de 20,000 reseñas de Amazon (vía PyCaret). El conjunto de datos incluye:

- Texto Original: Opiniones crudas de los usuarios.
- Etiqueta de Sentimiento: Clasificación binaria (1: Positivo, 0: Negativo).


III. ANÁLISIS EXPLORATORIO DE DATOS

A. Distribución de Sentimientos




Se observa un marcado desbalance de clases, con una predominancia de reseñas positivas (aprox. 15,000) frente a las negativas (aprox. 5,000). Este desbalance refleja una satisfacción general alta, pero representa un reto algorítmico, ya que los modelos tienden a "aprender mejor" de la clase mayoritaria. Por ello, en el modelado se dio especial importancia a la métrica Recall para asegurar que las quejas no pasen desapercibidas.

B. Caracterización del Lenguaje



- Positivas: El léxico se centra en términos de valor y emoción como "love", "great", "awesome" y "game". Esto sugiere que el éxito del producto está ligado a la experiencia de entretenimiento.
- Negativas: Aparecen términos funcionales y de frustración como "dont", "work", "get", "bad" y "kindle". Esto indica que el sentimiento negativo no es solo una "emoción", sino que nace de fallos específicos en el funcionamiento del software o hardware.

C. Análisis de Longitud de Texto



Los boxplots revelan que las reseñas negativas tienden a ser ligeramente más extensas y con mayor variabilidad que las positivas. Un cliente insatisfecho suele escribir más para detallar su problema, mientras que el satisfecho es más conciso (ej: "Great app!"). Tras la limpieza (lematización), la longitud se reduce en un 40%, eliminando el ruido y permitiendo que el modelo se enfoque solo en las palabras con carga semántica.


IV. COMPARACIÓN DE MODELOS SUPERVISADOS

A. Clasificadores


Se comparó un modelo basado en reglas (VADER) contra dos de aprendizaje automático supervisado (Naive Bayes y Regresión Logística) utilizando TF-IDF.

Modelo	Accuracy	Precisión en Negativos
VADER	82.17%	Baja (0.66)
Naive Bayes	85.63%	Media (0.90 Precision / 0.45 Recall)
Logistic Regression	88.52%	Alta (0.84 Precision / 0.64 Recall)

B. Análisis de matriz de confusión y ROC



El modelo de Regresión Logística es que presenta mejores resultados. Su Curva ROC con un AUC de 0.94 demuestra una capacidad de separación buena. Naive Bayes falla al identificar reseñas negativas (Falsos Positivos: 793). En contraste, la Regresión Logística logra detectar un 64% de las quejas totales (Recall), lo cual es vital para Amazon si desea actuar rápido ante un cliente molesto.



C. Interpretabilidad coeficientes palabras

Al analizar los pesos del modelo, vemos que "love" (+8.32) y "great" (+7.92) son los predictores positivos más fuertes.


Palabra positiva	Peso
love	8.324159
great	7.920137
easy	5.337758
awesome	4.776830
best	4.437676

Por otro lado, "waste" (-5.00) y "deleted" (-4.96) son los que más reducen la calificación. Esto permite crear una lista de palabras que, al aparecer en una nueva reseña, activen una alerta automática para el equipo de soporte.

Palabra negativa	Peso
waste	-5.002661
deleted	-4.962124
uninstalled	-4.328003
boring	-4.093107
stupid	-3.879254

V. MODELADO DE TÓPICOS (APRENDIZAJE NO SUPERVISADO)

Análisis de Importancia de Palabras por Tópico (Generación de Conocimiento)



El algoritmo LDA identificó 5 pilares temáticos:

- Tópico 1 (Hardware): Relacionado con dispositivos Kindle y Fire.
- Tópico 2 (Funcionalidad): El tópico más crítico, contiene palabras de negación ("dont", "work") y suele asociarse a sentimientos negativos.
- Tópico 3 (Juegos): El más exitoso, centrado en entretenimiento ("game", "fun", "play").
- Tópico 4 (Lectura/Libros): Enfocado en apps de lectura y contenido específico (ej: Bible).
- Tópico 5 (Plataforma): Referente a versiones de Android y Amazon Appstore.

VI. CONCLUSIONES

A partir del análisis realizado, se pueden destacar los siguientes hallazgos:

- El lenguaje utilizado en las reseñas permite identificar claramente el sentimiento del usuario, ya que las palabras reflejan directamente experiencias positivas o negativas.
- El modelo de Logistic Regression demostró ser el más efectivo para la clasificación del sentimiento, superando a los enfoques basados en reglas como VADER.
- Las reseñas positivas son más fáciles de identificar debido a la consistencia en el uso de palabras positivas, mientras que las reseñas negativas presentan mayor variabilidad y complejidad.
- El análisis de tópicos permitió identificar temas recurrentes dentro de las reseñas, lo que aporta una visión más profunda sobre los aspectos del producto que influyen en la percepción del usuario.
- Desde una perspectiva de negocio, el análisis de sentimiento permite identificar automáticamente problemas en productos o servicios, facilitando la toma de decisiones basada en datos.